

Pipeline de Dados: Análise Integrada da Copa do Mundo FIFA 2026

Engenharia de Dados na Nuvem com Databricks, Delta Lake e Arquitetura Medalhão

1. Introdução

1.1 Objetivo e Contexto

O objetivo deste projeto MVP (Produto Mínimo Viável) é construir um pipeline de dados na nuvem (Databricks / AWS), responsável por realizar o import dos dados brutos e heterogêneos e estruturá-los por meio da **Arquitetura Medalhão (Bronze → Silver → Gold)**. Com o suporte e a governança do **Unity Catalog**, os dados são higienizados, transformados e modelados para responder a perguntas estratégicas e gerar *insights* de alto valor.

Para a construção e validação do pipeline, foi escolhido o dataset **FIFA Open Data**, contendo informações relativas à **Copa do Mundo FIFA 2026**. Esta edição marca uma expansão histórica do torneio para **48 seleções** e **104 partidas**, introduzindo complexidades inéditas de logística, governança e análise esportiva.

A solução desenvolvida aborda frentes cruciais do evento, tais como:

- **Governança e Arbitragem:** Análise de neutralidade, distribuição por confederações e rigor disciplinar das equipes de arbitragem;
- **Gestão de Elencos:** Avaliação de valor de mercado, perfil etário (maturidade) das seleções e também por posição dos jogadores, e diversidade de clubes de origem dos atletas convocados;
- **Desempenho Tático:** Estudo de padrões e métricas associadas ao rendimento das equipes na competição.

1.2 Perguntas

Para melhor estruturação este item foi dividido em tópicos:

Tópico 1: Arbitragem e Governança Disciplinar

1. **Atribuição por Confederação:** Qual é a distribuição inicial de árbitros escolhidos para a Copa? Qual é a distribuição de árbitros por confederação (UEFA, CONMEBOL, CONCACAF, etc.) ao longo das fases do torneio? Qual confederação mais apitou jogos?
2. **Neutralidade de Arbitragem:** Existem partidas em que a confederação do árbitro principal é idêntica à de uma das seleções participantes?

3. **Rigor Disciplinar:** Quais são os 3 árbitros mais rigorosos da competição com base no histórico de faltas marcadas e cartões aplicados?

Tópico 2: Seleções e Staff (Squad Metrics)

4. **Maturidade e Idade:** Qual a média de idade por posição (GK, DEF, MID, FWD) e qual setor permite atletas mais veteranos?
5. **Valor de Mercado:** Quais são as 5 seleções mais valiosas em valor total de mercado e em valor médio por atleta?
6. **Diversidade de Clubes:** Qual seleção possui a maior pulverização de atletas em diferentes clubes de origem (total_clubes_representados)?

1.3 Origem, Licença e Estrutura dos Dados Brutos

Os dados foram coletados de dados abertos no Kaggle / FIFA Open Data sob licença de uso **Open Data Commons / CC BY 4.0** (permitindo uso, adaptação e redistribuição para fins educacionais e analíticos).

Estrutura das Tabelas Brutas (Camada Ingestion/Bronze):

- referees_raw (CSV): Dados cadastrais de árbitros (referee_id, name, country, confederacao, total_matches, avg_cards_per_game).
- squads_and_players_raw (JSON/CSV): Dados de atletas (player_id, name, team, position, date_of_birth, market_value_eur, club).
- matches_detailed_raw (CSV): Registro de partidas (match_id, stage_name, home_team, away_team, referee_id, home_fouls, away_fouls, home_yellow_cards, etc.).
- match_prediction_features_raw (Parquet): Tabela contendo estatísticas cruzadas de partidas e seleções.

2. Carga dos Dados (Import & Sincronização Databricks / GitHub)

A etapa de carga e import dos dados brutos foi desenhada para garantir reprodutibilidade, versionamento de código e governança de dados, conectando diretamente um repositório remoto do GitHub ao ambiente de execução do Databricks Workspace.

2.1 Estrutura do Repositório Git

O projeto foi organizado com a seguinte hierarquia de diretórios no GitHub:

└─ data/	
└─ raw/	# Datasets brutos (.csv, .json) do FIFA Open Data
└─ notebooks/	# Pipelines e scripts PySpark por camada
└─ 01_bronze_ingestion.py	# Carga e metadata (Bronze)
└─ 02_silver_cleansing.py	# Limpeza, deduplicação e tipagem (Silver)
└─ 03_gold_aggregations.py	# Modelagem dimensional e agregados (Gold)

```
| 04_analytics_insights.py    # Consultas de negócio e plots estatísticos
| docs/                      # Documentação e evidências
| README.md                  # Documentação oficial do projeto (MVP)
```

2.2 Sincronização Databricks e GitHub via Databricks GitHub App

A integração entre o Databricks Workspace e o GitHub foi realizada através do Databricks GitHub App (<https://docs.databricks.com/aws/en/repos/get-access-tokens-from-git-provider#github>)

2.3 Processo de Upload

Os arquivos do FIFA Open Data em formato .csv (referentes às listas de convocados, arbitragem e dados de partidas) foram inicialmente organizados na pasta data/raw/.

Ao realizar o git pull na interface do Databricks Repos, os arquivos de dados ficaram imediatamente acessíveis ao ecossistema PySpark do cluster pelo caminho relativo do workspace.

3. Modelagem e Catálogo de Dados

O projeto adota uma abordagem híbrida de modelagem no **Unity Catalog**:

1. **Camada Silver:** Modelo Relacional e padronizado em Delta Lake.
2. **Camada Gold:** Modelo Dimensional (Star Schema) e Tabelas Agregadas otimizadas para consumo analítico e BI.

A camada Silver foi modelada de forma relacional (com a tabela de partidas atuando como entidade central de eventos), garantindo a eliminação de duplicatas e a consistência das entidades. Já a camada Gold foi estruturada em Star Schema/Data Marts desnormalizados, unindo eventos e dimensões em métricas agregadas (ex: Rigor Index, Idade Média, Valor por Atleta) para otimizar diretamente as consultas de negócio.

```
copa_do_mundo (Catalog)
├── bronze (Schema)
│   ├── referees_bronze
│   ├── match_prediction_features_bronze
│   ├── player_stats_bronze
│   ├── match_team_stats_bronze
│   ├── squads_and_players_bronze
│   └── matches_detailed_bronze
├── silver (Schema)
│   ├── referees_silver
│   ├── match_prediction_features_silver
│   ├── player_stats_silver
│   ├── match_team_stats_silver
│   ├── squads_and_players_silver
│   └── matches_detailed_silver
└── gold (Schema)
    ├── gold_player_performance
    ├── gold_referee_analytics
    └── gold_squad_metrics
```

4. Pipeline de Dados ETL

O pipeline de dados foi estruturado de forma modular em notebooks PySpark encadeados no Databricks:

1. `01_camada_bronze.py`: Leitura dos arquivos brutos e criação das Delta Tables Bronze.
2. `02_camada_silver.py`: Limpeza, deduplicação, casting, padronização de datas, enriquecimento dos dados.
3. `03_camada_gold.py`: Criação de tabelas analíticas para os tópicos de Arbitragem e Seleções.
4. `04_analytics_insights.py`: Execução das consultas SQL/PySpark e geração das estatísticas e visualizações.

O detalhamento completo do tratamento realizado encontra-se nos respectivos notebooks e as evidências na estrutura /docs com os prints relacionados.

5. Qualidade de Dados

Durante a fase de auditoria da camada Bronze, foram identificadas e resolvidas as seguintes inconsistências:

1. Valores Nulos:

- *Problema*: Atletas sem informação de valor de mercado (`market_value_eur = NULL`).
- *Solução*: Preenchimento por imputação com valor "0" na camada Silver para evitar distorções e erros em somatórios.

2. Formatação:

- *Problema*: texto ilegível e caracteres especiais nos nomes de jogadores e árbitros devido à problema de codificação nos dados (Mojibake)
- *Solução*: Criação de um dicionário completo de de-para dos caracteres identificados nos dados.

3. Cálculo da idade dos jogadores:

- *Problema*: O uso da função dinâmica `current_date()` alteraria as médias de idade das seleções conforme a data de execução da pipeline.
- *Solução*: Fixou-se a data oficial de início do torneio (2026-06-11), dividindo os dias exatos por 365.25 e aplicando `floor()` para computar idades completas.

4. Verificação da integridade dos dados de posse de bola (%) por partida:

- *Problema*: Algumas estatísticas de posse de bola das seleções por partida não somam 100% por motivos de contabilização e métricas utilizadas (ex.: quando a bola está em disputa direta).
- *Solução*: Casos de posse de bola das seleções por partida abaixo de 100% não foram tratados. A única verificação criada foi para garantir que a soma das duas seleções não ultrapasse 100% na mesma partida.

O detalhamento completo do tratamento realizado encontra-se nos respectivos notebooks e as evidências na estrutura /docs com os prints relacionados.

6. Análise de Dados e Respostas aos Objetivos

Tópico 1: Arbitragem e Governança Disciplinar


1. Distribuição de Árbitros por Confederação

A UEFA representa a maior fatia do quadro de arbitragem (39,3%), seguida pela CONMEBOL (21,4%) e CONCACAF (14,3%). A variação dessa distribuição com base nos árbitros escolhidos ao longo das fases da Copa é apresentada graficamente.

A UEFA e a CONMEBOL mantêm o maior volume absoluto de jogos apitados na Fase de Grupos, refletindo a maior proporção de árbitros convocados inicialmente.

Nas Fases Finais (Oitavas até a Final), há uma filtragem onde árbitros de confederações cujas seleções avançam para as fases decisivas deixam de apitar (devido à neutralidade de confederação/país), elevando a presença relativa de árbitros neutros das confederações com menor número de seleções remanescentes (como CONCACAF, AFC e CAF).

Distribuição Inicial de Árbitros por Confederação — Copa 2026




> See performance (1)

Table

	^B _A _C confederacao	² ₁ ₃ total_arbitros
1	UEFA	11
2	CONMEBOL	6
3	AFC	4
4	CONCACAF	4
5	CAF	3

> 3 dataframes: df_confed_dist, pdf_confed, pdf_pivot

Distribuição Proporcional de Árbitros por Confederação — Copa 2026



> 4 dataframes: df_confed_fases, df_matches_silver, df_matches_staged, df_referees_...


Table



	A ^B _C confederacao	A ^B _C fase_agrupada	A ^B _C jogos_apitados
1	UEFA	1. Fase de Grupos	28
2	CONMEBOL	1. Fase de Grupos	13
3	CAF	1. Fase de Grupos	11
4	CONCACAF	1. Fase de Grupos	11
5	AFC	1. Fase de Grupos	9
6	UEFA	2. 16 avos de Final	7
7	CONMEBOL	2. 16 avos de Final	5
8	CONCACAF	2. 16 avos de Final	2
9	AFC	2. 16 avos de Final	1
10	CAF	2. 16 avos de Final	1
11	UEFA	3. Fases Finais (Oitavas até Fin...	8
12	AFC	3. Fases Finais (Oitavas até Fin...	4
13	CONMEBOL	3. Fases Finais (Oitavas até Fin...	2
14	CONCACAF	3. Fases Finais (Oitavas até Fin...	2


> 2 dataframes: pdf_fases, pdf_pivot_fases

Atuação de Árbitros por Confederação em cada Fase da Copa do Mundo



> 6 dataframes: df_confed_fases, df_matches_silver, df_matches_staged, df_referees_...

Distribuição da Arbitragem por Confederação entre as Fases da Copa 2026



2. Teste de Neutralidade (Mesma Confederação)

Historicamente, a FIFA proíbe estritamente que um árbitro apite jogos de sua própria seleção nacional. No entanto, para partidas envolvendo seleções da mesma confederação (por exemplo, um árbitro da UEFA apitando um jogo entre duas seleções europeias ou entre uma europeia e uma de outra confederação), as regras permitem em cenários específicos — especialmente em confrontos diretos entre equipes da mesma confederação ou nas fases finais do torneio.

Do total de 104 partidas na Copa, 39 partidas tiveram o árbitro e pelo menos 1 das seleções pertencentes à mesma Confederação de futebol.

> 3 dataframes: df_matches, df_same_confed_matches, tabela_jogos_mesma_confed

Table										
	id match_id	id fase	id selecao...	id confed_mandante	id ranking...	id selecao_visitante	id confed_visitante	id ranking_fifa_visitante	id arbitro	id confed_arbitro
1	5	Group Stage	Qatar	AFC	56	Switzerland	UEFA	19	Yoshimi Yamashita	AFC
2	7	Group Stage	Haiti	CONCACAF	83	Scotland	UEFA	39	Daniele Orsato	UEFA
3	8	Group Stage	Australia	AFC	27	Türkiye	UEFA	26	Anthony Taylor	UEFA
4	9	Group Stage	Germany	UEFA	10	Curaçao	CONCACAF	82	Clément Turpin	UEFA
5	12	Group Stage	Sweden	UEFA	25	Tunisia	CAF	45	Mustapha Ghorbal	CAF
6	13	Group Stage	Spain	UEFA	2	Cabo Verde	CAF	67	Victor Gomes	CAF
7	15	Group Stage	Saudi Arabia	AFC	58	Uruguay	CONMEBOL	16	Yoshimi Yamashita	AFC
8	17	Group Stage	France	UEFA	3	Senegal	CAF	15	João Pinheiro	UEFA
9	18	Group Stage	Iraq	AFC	55	Norway	UEFA	44	Maurizio Mariani	UEFA
10	19	Group Stage	Argentina	CONMEBOL	1	Algeria	CAF	28	Jalal Jayed	CAF
11	22	Group Stage	England	UEFA	4	Croatia	UEFA	11	Glenn Nyberg	UEFA
12	24	Group Stage	Uzbekistan	AFC	50	Colombia	CONMEBOL	13	Yael Falcón	CONMEBOL
13	28	Group Stage	Switzerland	UEFA	19	Bosnia and Herzegovina	UEFA	64	Daniele Orsato	UEFA
14	30	Group Stage	Scotland	UEFA	39	Morocco	CAF	7	Anthony Taylor	UEFA
15	32	Group Stage	Türkiye	UEFA	26	Paraguay	CONMEBOL	54	Jesús Valenzuela	CONMEBOL

39 rows 6.912s runtime

Refreshed 12h ago

3. Rigor Disciplinar:

Para definir e classificar os árbitros mais rigorosos de forma robusta e matematicamente justa, não foram avaliados exclusivamente o volume absoluto de faltas apitadas, nem exclusivamente o histórico de cartões. A proposta para avaliação foi a criação do Índice Composto de Rigor da Arbitragem `indice_rigor` que avalia a média de faltas e a média de cartões. O objetivo da criação do índice foi evitar distorção por amostras (árbitros com poucos jogos apitados), e a intensidade da punição (um árbitro que apita muitas faltas simples é menos rigoroso do que um que expulsa um atleta por uma única falta).

Os três árbitros mais rigorosos de acordo com o critério adotado foram: Yael Falcón (Argentina), Ma Ning (China) e Jalal Jayed (Marrocos).

3 dataframes: df_referees, df_rigor_arbitros, top_3_rigorosos

Table +

	referee_id	referee_name	country	confederacao	total_jogos_apitados	media_faltas	media_cartoes	indice_rigor
1	26	Yael Falcón	Argentina	CONMEBOL	3	24	5.4	40.2
2	13	Ma Ning	China	AFC	4	22.75	5.5	39.25
3	19	Jalal Jayed	Morocco	CAF	4	25.25	4.6	39.05

Tópico 2: Seleções e Staff (Squad Metrics)

4. Maturidade e Idade:

As seleções com maiores médias de idade são: Panama (30), Irã (29,6), Colombia (29,6), Cabo verde (29,2) e Qatar (28,9).

>  See performance (1)

Table ▾



	A ^B _C selecao	1.2 media_idade
1	Panama	30
2	IR Iran	29.8
3	Colombia	29.6
4	Cabo Verde	29.2
5	Qatar	28.9
6	Brazil	28.8
7	Scotland	28.7
8	Argentina	28.7
9	Egypt	28.7
10	Paraguay	28.5
11	Congo DR	28.5
12	Austria	28.2
13	Uruguay	28.2
14	Jordan	28.1
15	Saudi Arabia	28

As seleções com menores médias de idade são: Costa do Marfim (25,3), Ecuador (25,6), Bosnia e Herzegovina(26), Marrocos (26,1) e Espanha (26,2).

>  See performance (1)

Table  

	A ^B _C selecao	1.2 media_idade
34	France	26.6
35	Senegal	26.6
36	Canada	26.5
37	Algeria	26.5
38	USA	26.4
39	Ghana	26.4
40	Iraq	26.4
41	Norway	26.3
42	South Africa	26.3
43	Tunisia	26.2
44	Spain	26.2
45	Morocco	26.1
46	Bosnia and Herzegovi...	26
47	Ecuador	25.6
48	Côte d'Ivoire	25.3



48 rows | 4.141s runtime

Para responder se existe relação entre a idade e o desempenho, analisamos a correlação estatística (ou o cruzamento entre a média de idade e a fase de eliminação/posição final)

Entre as 4 primeiras seleções da Copa temos idades médias variando de 26,2 - Espanha até 28,7 - Argentina.

> [See performance \(1\)](#)

Table +

	A ^B _C selecao	1.2 media_idade	A ^B _C fase_final_alcancada	1 ² ₃ vitorias	1 ² ₃ saldo_gols
1	Argentina	28.7	Final	7	11
2	Spain	26.2	Final	7	13
3	England	26.7	Third-place match	6	8
4	France	26.6	Third-place match	6	10
5	Switzerland	27.8	Quarter-finals	3	4
6	Belgium	27.1	Quarter-finals	3	7
7	Norway	26.3	Quarter-finals	4	2
8	Morocco	26.1	Quarter-finals	3	4
9	Colombia	29.6	Round of 16	3	4
10	Brazil	28.8	Round of 16	3	6
11	Egypt	28.7	Round of 16	1	1
12	Paraguay	28.5	Round of 16	1	-3
13	Portugal	27.5	Round of 16	2	5
14	Mexico	27.5	Round of 16	4	7
15	Canada	26.5	Round of 16	2	3

↓

▼

48 rows

4.081s runtime

Pelos dados analisados, a posição de goleiro é a que permite atletas mais veteranos. É provável que isso aconteça por 2 motivos: menor exigência de intensidade física em comparação com as demais posições, e a escolha de atletas mais experientes e maduros para uma posição tão importante como goleiro. É apresentado um gráfico com a distribuição de idades por posição, média, mediana e outliers.


> [See performance \(1\)](#) ✓ Checked for improvements

> 2 dataframes: df_idade_posicao, df_players

Table + Q Y ⌵ ⌶

	A _C position	1.2 media_idade	1 ^o idade_maxima	1 ^o idade_minima	1 ^o total_jogadores
1	GK	30.12	43	18	145
2	DEF	27.89	40	19	421
3	MID	27.18	41	17	369
4	FWD	27.11	41	18	313

↓ ⌵ 4 rows 1.769s runtime Refreshed 11h ago



5. Valor de Mercado:

Para analisar o Valor de Mercado na camada Gold (gold_squad_metrics), consideram-se duas abordagens complementares: o Valor Total do Elenco (soma do valor de mercado de todos os atletas convocados) e o Valor Médio por Atleta (valor total dividido pelo número de atletas na convocação oficial - 26 jogadores).

TOP 5 em Valor Total de Mercado e Valor médio por atleta: Espanha, França, Inglaterra, Portugal e Argentina (ver tabela correspondente).

> [View](#) See performance (2) ✓ Checked for improvements

> 4 dataframes: df_squad_metrics, df_team_info, top5_valor_medio, top5_valor_total

=== TOP 5 SELEÇÕES MAIS VALIOSAS (VALOR TOTAL) ===

	A ^B selecao	A ^B confederacao	1 ² total_jogadores	1 ² valor_total_mercado_eur	1.2 valor_medio_atleta_eur
1	Spain	UEFA	26	2134173029	82083578.04
2	France	UEFA	26	1546204469	59469402.65
3	England	UEFA	26	1321818896	50839188.31
4	Portugal	UEFA	26	1145908765	44073414.04
5	Argentina	CONMEBOL	26	1025039444	39424594

5 rows 5.770s runtime Refreshed 11h ago

=== TOP 5 SELEÇÕES MAIS VALIOSAS (MÉDIA POR ATLETA) ===

	A ^B selecao	A ^B confederacao	1 ² total_jogadores	1 ² valor_total_mercado_eur	1.2 valor_medio_atleta_eur
1	Spain	UEFA	26	2134173029	82083578.04
2	France	UEFA	26	1546204469	59469402.65
3	England	UEFA	26	1321818896	50839188.31
4	Portugal	UEFA	26	1145908765	44073414.04
5	Argentina	CONMEBOL	26	1025039444	39424594

5 rows 5.770s runtime Refreshed 11h ago

6. Diversidade de Clubes:

Foi criado o índice de pulverização *indice_pulverizacao* (total de clubes representados em cada seleção / total de convocados). Um índice de valor "1" indica que os 26 convocados de uma seleção jogam em clubes distintos.

O resultado é apresentado na tabela final.

Analizando os dados podemos observar que:

Cabo Verde e Suécia possuem índice "1", ou seja, todos os 26 convocados de cada seleção jogam em clubes distintos. A campeã Espanha possui índice "0,5", ou seja, os 26 jogadores convocados estão distribuídos em apenas 13 clubes. Analisando os dados da Espanha temos: Barcelona (8 convocados), Atlético de Madrid (3), Athletic Bilbao (3) e Arsenal (3).

See performance (1) ✓ Checked for improvements

3 dataframes: df_club_diversity, df_squad_metrics, df_team_info

Table +

	A _C selecao	A _C confederacao	1 ₃ total_jogadores	1 ₃ total_clubes_representados	1.2 indice_pulverizacao
1	Cabo Verde	CAF	26	26	1
2	Sweden	UEFA	26	26	1
3	Haiti	CONCACAF	26	25	0.96
4	Côte d'Ivoire	CAF	26	25	0.96
5	Colombia	CONMEBOL	26	24	0.92
6	Algeria	CAF	26	24	0.92
7	Bosnia and Herzegovi...	UEFA	26	24	0.92
8	Switzerland	UEFA	26	24	0.92
9	Morocco	CAF	26	24	0.92
10	Croatia	UEFA	26	24	0.92
11	Tunisia	CAF	26	24	0.92
12	Congo DR	CAF	26	24	0.92
13	USA	CONCACAF	26	24	0.92
14	Ecuador	CONMEBOL	26	23	0.88
15	Japan	AFC	26	23	0.88

48 rows 46.172s runtime Refreshed 3h ago

> 3 dataframes: df_club_diversity, df_squad_metrics, df_team_info

Table +

	A ^B selecao	A ^B confederacao	1 ^o total_jogadores	1 ^o total_clubes_representados	1.2 indice_pulverizacao
34	France	UEFA	26	18	0.69
35	Belgium	UEFA	26	18	0.69
36	Portugal	UEFA	26	17	0.65
37	Uzbekistan	AFC	26	16	0.62
38	Türkiye	UEFA	26	16	0.62
39	England	UEFA	26	16	0.62
40	Jordan	AFC	26	14	0.54
41	IR Iran	AFC	26	14	0.54
42	Egypt	CAF	26	14	0.54
43	Spain	UEFA	26	13	0.5
44	Germany	UEFA	26	13	0.5
45	South Africa	CAF	26	12	0.46
46	Czechia	UEFA	26	11	0.42
47	Saudi Arabia	AFC	26	9	0.35
48	Qatar	AFC	26	8	0.31

48 rows 46.172s runtime Refreshed 3h ago

7. Autoavaliação

7.1 Alcance dos Objetivos

O MVP atingiu o objetivo traçado no escopo inicial. Foi possível estruturar um pipeline completo no Databricks, implementar com sucesso a Arquitetura Medalhão (Bronze/Silver/Gold) e responder de forma fundamentada e visual as perguntas formuladas.

7.2 Experiência pessoal

Considero que o trabalho foi muito gratificante e ao mesmo desafiador. Trabalho na área de Telecomunicações e este foi meu primeiro Sprint na pós e 1º MVP. A jornada de aprendizado do Databricks, ferramentas Git, Python e SQL foi intensa mas ao mesmo tempo muito útil e proveitosa.

A oportunidade conhecer em maiores detalhes a ferramenta Databricks foi muito boa, é uma ferramenta muito valiosa para trabalhar com dados. As dificuldades que apareceram ao longo projeto foram contornadas consultando documentação (ex.: integração Databricks <-> Git), e usando o assistente de IA que eventualmente corrigiu alguns (talvez muitos!) erros de código Python e queries SQL.

Iniciei o trabalho analisando dados da área de Telecomunicações mas devido a qualidade dos dados (ou a falta de qualidade!) acabei trocando muito tardiamente para análise dos dados da FIFA World CUP 2026. Espero que todo o esforço seja considerado na avaliação. Infelizmente devido a falta de tempo não foi possível realizar a análise mais complexa (Tópico 3) que tinha como objetivo correlacionar dados como: posse de bola, finalizações, faltas, gols, entre outras métricas para tentar identificar o que as seleções que chegaram às fases finais tinham em comum (Dominaram a posse de bola ao longo da Copa? Foram mais eficientes nas suas finalizações? Os jogadores percorreram distâncias maiores por paritda? Atingiram maiores velocidades médias/aceleração? Defendiam com a mesma velocidade/aceleração que atacavam?)

7.3 Trabalhos Futuros

Finalizar a análise do **Tópico 3 - Desempenho Tático**: Estudo de padrões e métricas associadas ao rendimento das equipes na competição.

7.4 Agradecimentos

Agradeço à PUC e aos professores/instrutores por toda a disponibilidade e paciência ao longo da jornada.